

Academia de Studii Economice din București
Facultatea de Cibernetică, Statistică și Informatică Economică

Proiect Pachete Software

Analiză Bancară a Pieței de Credite și Depozite

Studenti:
Miroiu Mihai - Ștefan
Prisnel Aurelia - Georgiana
Grupa: 1091 | Seria: D

Cuprins

Introducere.....	3
Python.....	4
Problema 1.....	4
Problema 2.....	5
Problema 3.....	7
Problema 4.....	8
Problema 5.....	10
Problema 6.....	11
Problema 7.....	13
SAS.....	16
Problema 1.....	16
Problema 2.....	19
Problema 3.....	22

Introducere

În contextul economic actual, marcat de o concurență ridicată pe piața serviciilor financiare, sectorul bancar trebuie să adopte decizii strategice bazate pe analiza cantitativă a datelor (abordare de tip *data-driven*) pentru a-și menține și crește profitabilitatea. Una dintre principalele surse de capital pentru o bancă comercială este atragerea de fonduri prin intermediul depozitelor la termen. Totuși, metodele clasice de marketing direct, cum ar fi campaniile de telemarketing generalizate (cold-calling), implică alocarea unor resurse umane și financiare semnificative. Mai mult, acestea înregistrează adesea rate de conversie scăzute și pot genera o experiență negativă pentru clienții care nu prezintă interes pentru astfel de produse.

Prezentul proiect își propune să abordeze această problemă de business prin analiza detaliată a activității unei organizații bancare, vizând identificarea oportunităților de optimizare a campaniilor de promovare și de extindere eficientă a portofoliului de clienți. Obiectivul economic principal este construirea unui profil clar al clientului predispus la economisire și dezvoltarea unui sistem predictiv care să anticipeze probabilitatea ca un client să accepte deschiderea unui depozit la termen.

Prin studierea interacțiunilor trecute, analiza se bazează pe o colecție complexă de variabile: factori demografici și sociali (vârstă, ocupație, nivel de educație, stare civilă), indicatori financiari (balanța contului, existența altor credite active) și elemente specifice campaniilor de comunicare (durata apelului, numărul de contactări anterioare).

Pentru a soluționa această problemă, proiectul utilizează un instrumentar analitic avansat, demonstrând capabilitățile a două pachete software de top din domeniul științei datelor: **Python** și **SAS**. Pe de o parte, ecosistemul Python a fost utilizat pentru dezvoltarea unei aplicații web interactive (prin intermediul bibliotecii Streamlit), care permite filtrarea dinamică a datelor, prelucrarea statistică, vizualizarea tendințelor și antrenarea unor modele de *Machine Learning* (clusterizare, regresie logistică și regresie multiplă). Pe de altă parte, pachetul SAS a asigurat gestiunea structurală a datelor, procesarea condițională, îmbinarea seturilor prin proceduri specifice și generarea unor rapoarte de business riguroase.

Prin îmbinarea analizei exploratorii cu tehnicile de modelare predictivă, lucrarea de față depășește stadiul de simplă raportare. Rezultatele obținute se concretizează într-un set de recomandări acționabile, menite să asigure managementului băncii suportul necesar pentru direcționarea inteligentă a bugetelor de marketing exclusiv către segmentele de clienți cu un potențial real de conversie.

Python

Problema 1

a) Definirea problemei: obiectivul economic vizat

Obiectivul acestei etape este crearea unui instrument decizional flexibil și automatizat (Dashboard). Din punct de vedere economic, se vizează reducerea timpului de procesare a datelor de către departamentele non-tehnice. Prin implementarea unui modul dinamic de încărcare a fișierelor (în loc de ancorarea statică a unui singur set de date în cod), managementul poate utiliza aceeași aplicație în viitor pentru rapoarte lunare sau trimestriale diferite, fără a necesita intervenția unui programator.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

În această secțiune de pre-procesare, variabilele utilizate sunt de natură tehnică, menite să gestioneze fluxul informațional:

fișier_încărcat: variabilă de tip binar/obiect care captează fișierul .csv încărcat de utilizator din interfața grafică.

st.session_state['date_încărcate']: variabilă de memorie a aplicației. Asigură persistența datelor, astfel încât fișierul să nu trebuiască reîncărcat la fiecare schimbare de pagină.


st.session_state['pagina_curenta']: variabilă de stare care memorează secțiunea activă (Analiză sau Modele), controlând fluxul de vizualizare al managerului.

df: structură de date tabelară (DataFrame) care stochează temporar informațiile extrase din fișierul brut.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Deoarece acest modul reprezintă interfața de conectare și navigare, nu se aplică algoritmi statistici sau modele matematice în această etapă. Principala procedură utilizată este funcția de parsare **pd.read_csv** din pachetul Pandas. Pentru a spori fiabilitatea, a fost utilizat parametrul **sep=None** și **engine='python'**, un algoritm intern care detectează automat delimitatorul fișierului (virgulă, punct și virgulă etc.), prevenind erorile de formatare la importul datelor.

d) Prezentarea rezultatelor:



e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Această etapă nu generează încă rezultate economice numerice, însă concluzia de business este că organizația beneficiază acum de o aplicație user-friendly și complet funcțională. Recomandarea pentru business este instruirea personalului din departamentele de marketing sau risc să utilizeze acest modul de "Upload" pentru a-și importa propriile extrase de date, standardizând astfel modul în care compania vizualizează și analizează portofoliile de clienți.

Problema 2

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic al acestei secțiuni este dezvoltarea unui modul de segmentare dinamică a bazei de clienți (Market Segmentation). În analiza de business, o campanie de marketing generalizată este inefficientă. Prin acest modul, managementul vizualizează portofoliul în mod granular, având posibilitatea de a izola și analiza micro-segmente (ex: clienți tineri, cu studii superioare, care nu au credite active) pentru a descoperi nișe profitabile și a personaliza ofertele de depozite la termen.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru a realiza filtrarea, s-au utilizat atât variabile de stare ale aplicației, cât și variabile economice din setul de date:

Variabile demografice și financiare:

age (vârsta): variabilă numerică utilizată pentru stabilirea intervalului de selecție (slider).

marital (starea civilă) și education (nivelul de educație): variabile categoricale utilizate pentru filtrarea profilului social.

loan (credit de nevoi personale): variabilă binară/categorială esențială pentru a exclude sau include clienții deja îndatorați.

Variabile tehnice:

date_filtrate: un DataFrame Pandas care reprezintă copia bazei de date inițiale, actualizată în timp real doar cu rândurile care îndeplinesc condițiile selectate.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Metoda principală utilizată este filtrarea condițională multiplă (Boolean Indexing) prin intermediul pachetului Pandas. Se extrag dinamic valorile extreme (minim și maxim) ale variabilei continue age folosind funcțiile .min() și .max() pentru a calibra widget-ul de tip slider. Se utilizează metoda .isin() pentru listele categoricale, permițând selecția multiplă (clauză logică de tip SAU în interiorul aceleiași categorii). Condițiile sunt aplicate cumulativ asupra bazei de date prin intersecția măștilor booleene, rezultând sub-eșantionul date_filtrate care va alimenta graficele și modelele ulterioare.

d) Prezentarea rezultatelor: capturi de ecran

3. Filtre Interactivitate

Selectează vârsta:

1895

Lasă gol pentru a selecta toate categoriile.

Stare civilă (marital):

Choose options

Educație (education):

Choose options

Credit personal (loan):

Choose options

3. Filtre Interactivitate

Selectează vârsta:

1895

Lasă gol pentru a selecta toate categoriile.

Stare civilă (marital):

Choose options

Educație (education):

Choose options

Credit personal (loan):

Choose options

3. Filtre Interactivitate

Selectează vârsta:

3295

Lasă gol pentru a selecta toate categoriile.

Stare civilă (marital):

married x

Educație (education):

Choose options

Credit personal (loan):

yes x

Indicatori Cheie (KPIs)

Total Clienți	Vârsta Medie	Balanța Medie	Clienți cu Credit Ipotecar
11,162	41.2 ani	1528.5 €	5281

Baza de date

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcon
0	59	admin.	married	secondary	no	2343	yes	no	unknown	5	may	1042	1	-1	0	unknown
1	56	admin.	married	secondary	no	45	no	no	unknown	5	may	1467	1	-1	0	unknown
2	41	technician	married	secondary	no	1270	yes	no	unknown	5	may	1389	1	-1	0	unknown
3	55	services	married	secondary	no	2476	yes	no	unknown	5	may	579	1	-1	0	unknown
4	54	admin.	married	tertiary	no	184	no	no	unknown	5	may	673	2	-1	0	unknown
5	42	management	single	tertiary	no	0	yes	yes	unknown	5	may	562	2	-1	0	unknown

Indicatori Cheie (KPIs)

Total Clienți	Vârsta Medie	Balanța Medie	Clienți cu Credit Ipotecar
784	44.1 ani	976.1 €	478

Baza de date

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcon
6	56	management	married	tertiary	no	830	yes	yes	unknown	6	may	1201	1	-1	0	unknown
40	60	blue-collar	married	primary	no	1262	yes	yes	unknown	13	may	1015	1	-1	0	unknown
52	59	retired	married	secondary	no	1521	yes	yes	unknown	14	may	1125	2	-1	0	unknown
66	49	unknown	married	primary	no	341	yes	yes	unknown	15	may	520	2	-1	0	unknown
76	39	technician	married	tertiary	no	94	yes	yes	unknown	16	may	813	1	-1	0	unknown
88	34	blue-collar	married	primary	no	695	yes	yes	unknown	16	may	1064	4	-1	0	unknown
107	36	blue-collar	married	secondary	no	408	yes	yes	unknown	20	may	1063	2	-1	0	unknown

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Interactivitatea acestui modul permite aplicarea analizei de tip Drill-Down. Concluzia economică este că decizia de subscriere variază masiv în funcție de caracteristicile socio-demografice. De exemplu, prin manipularea filtrelor, se poate observa imediat dacă

segmentul „Seniori fără credite active” reprezintă o pondere mai valoroasă decât segmentul „Tineri”. Recomandarea directă pentru echipa de vânzări este utilizarea acestor filtre înainte de lansarea unei campanii telefonice, pentru a extrage o listă scurtă (subset) cu cel mai relevant grup țintă, maximizând astfel indicatorul ROI (Return on Investment) al campaniei de promovare a depozitelor.

Problema 3

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic al acestei secțiuni este oferirea unei viziuni de ansamblu instantanee (tip Executive Summary) asupra „sănătății” și potențialului financiar al segmentului de piață selectat. Managementul băncii nu are timpul necesar pentru a parcurge mii de rânduri de date brute; prin urmare, este necesară extragerea și afișarea unor indicatori macroeconomici cheie (KPIs) care să valideze sau să invalideze rapid profitabilitatea unui anumit grup țintă înainte de a aloca bugete de marketing.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru calcularea indicatorilor, s-au extras date agregate din sub-eșantionul creat anterior (date_filtrate), utilizând următoarele variabile economice:

age (vârsta): variabilă numerică utilizată pentru a determina profilul demografic mediu al grupului.

balance (balanța contului): variabilă numerică continuă, vitală pentru estimarea lichidității medii și a capacității de economisire a clienților.

housing (credit ipotecar): variabilă categorială (yes/no) utilizată pentru a cuantifica gradul de îndatorare imobiliară pe termen lung al segmentului.

job (ocupația): variabilă categorială utilizată ca indicator de rezervă pentru a arăta diversitatea profesională.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Metodele de calcul utilizate se încadrează în categoria statisticii descriptive. Funcția len() este utilizată pentru numărarea totalului de înregistrări valide (dimensiunea eșantionului) și numărarea condițională (clauza == 'yes'), pentru a afla volumul exact de clienți îndatorați. Calculul mediei aritmetice se face folosind metoda .mean() pe seriile de date numerice (age și balance), rezultatele fiind rotunjite (round()) pentru o afișare ergonomică. Am implementat un algoritm de tip try-except pentru a asigura stabilitatea aplicației în cazul în care structura bazei de date se modifică (de exemplu, dacă setul de date importat nu conține variabila financiară balance, sistemul va afișa automat un KPI alternativ bazat pe numărul de ocupații distincte, utilizând funcția .nunique()).

d) Prezentarea rezultatelor: capturi de ecran

Indicatori Cheie (KPIs)

Total Clienți

784

Vârsta Medie

44.1 ani

Balanța Medie

976.1 €

Clienți cu Credit Ipotecar

478

Baza de date ↗

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcon
411	33	blue-collar	married	primary	no	-191	yes	yes	cellular	9	jul	1290	4	-1	0	unknow
413	49	blue-collar	married	primary	no	3	no	yes	cellular	9	jul	1439	6	-1	0	unknow
418	45	entrepreneur	married	unknown	no	3133	yes	yes	cellular	10	jul	804	1	-1	0	unknow
419	34	admin.	married	secondary	no	-33	yes	yes	cellular	10	jul	961	1	-1	0	unknow
427	54	technician	married	secondary	no	-315	no	yes	cellular	10	jul	2029	1	-1	0	unknow
441	35	entrepreneur	married	secondary	no	2436	no	yes	cellular	14	jul	1397	3	-1	0	unknow
444	50	technician	married	secondary	no	156	no	yes	cellular	14	jul	1130	3	-1	0	unknow
450	59	management	married	tertiary	no	296	no	yes	cellular	15	jul	805	3	-1	0	unknow
457	51	entrepreneur	married	secondary	no	-799	no	yes	cellular	15	jul	1001	3	-1	0	unknow
475	43	blue-collar	married	secondary	no	184	no	yes	cellular	16	jul	1019	11	-1	0	unknow

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Indicatorii de tip KPI oferți de acest modul sunt esențiali pentru luarea deciziilor rapide. De exemplu, un grup de clienți poate afișa o Balanță Medie foarte mare, ceea ce inițial i-ar califica drept ținte perfecte pentru depozite. Totuși, dacă indicatorul Clienți cu Credit Ipotecar este la rândul său foarte ridicat, deducția economică este că veniturile lor, deși mari, sunt blocate în rate lunare, reducând disponibilitatea lichidităților. Recomandarea pentru departamentul de Business Intelligence este să urmărească aceste carduri în timp real atunci când aplică filtrele, pentru a identifica „sweet spot-ul” (grupul ideal): clienți cu balanțe peste medie și grad de îndatorare ipotecară minim.

Problema 4

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic al acestei secțiuni este auditarea rapidă a datelor și profilarea statistică detaliată a portofoliului. Înainte de a rula campanii de marketing costisitoare sau de a antrena modele predictive, analiștii de business trebuie să se asigure că datele filtrate sunt corecte (fără anomalii evidente) și să înțeleagă distribuția financiară a clienților. Această secțiune acționează ca un instrument de control al calității și de evaluare a volatilității (de exemplu, cât de mult variază balanța conturilor de la un client la altul).

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Acest modul acționează global asupra bazei de date pre-filtrate (date_filtrate).

Pentru funcția iloc, se utilizează structura tabelară în ansamblu (matricial), fără a discrimina între tipurile de variabile.

Pentru funcția de statistici descriptive, algoritmul selectează automat și analizează exclusiv variabilele numerice continue și discrete, precum:

age (vârsta), balance (sold bancar), duration (durata apelurilor) și campaign (numărul de contactări).

c) Metode de calcul, algoritmi, formule de calcul utilizate

S-au utilizat două metode distincte din pachetul Pandas:

Felierea matricială (Matrix Slicing): Prin proprietatea `.iloc[:5, :5]`, se utilizează indexarea pozițională pentru a extrage un sub-tablou format din primele 5 rânduri și primele 5 coloane. Este un algoritm de eșantionare non-aleatoare pentru inspecție vizuală.

Statistica Descriptivă: Metoda `.describe()` aplică un set standardizat de formule statistice pe fiecare coloană numerică:

Tendința centrală: Media aritmetică (Mean) și Mediana (Percentila 50%).

Dispersia (Volatilitatea): Abaterea standard (Std - Standard Deviation) și Amplitudinea (Min și Max).

Poziția: Quartilele (25% și 75%): utilizate pentru a înțelege distribuția masei de clienți.

d) Prezentarea rezultatelor: capturi de ecran

Vizualizare parțială (iloc - primele 5 rânduri și 5 coloane)

	age	job	marital	education	default
6	56	management	married	tertiary	no
40	60	blue-collar	married	primary	no
52	59	retired	married	secondary	no
66	49	unknown	married	primary	no
76	39	technician	married	tertiary	no

Statistici descriptive dinamice

	age	balance	day	duration	campaign	pdays	previous
count	784	784	784	784	784	784	784
mean	44.1212	976.0548	16.0179	333.6467	2.7742	45.4107	0.7207
std	8.4024	2686.5231	8.3424	357.4484	3.2748	104.9269	2.7971
min	32	-6847	1	2	1	-1	0
25%	36	24.75	9	107	1	-1	0
50%	44	369.5	16	204	2	-1	0
75%	51	1127.5	21	410.5	3	-1	0
max	72	51439	31	3076	43	774	58

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Tabelul statistic oferă insight-uri de business imediate și profunde. De exemplu, prin compararea mediei (mean) cu mediana (50%) pentru variabila balance, managementul poate identifica asimetrii în distribuția averii: dacă media este mult mai mare decât mediana, înseamnă că portofoliul este susținut de o minoritate de clienți foarte bogați („whales”). De asemenea, analizând valorile maxime (max) comparativ cu quartila 3 (75%), se pot identifica clienții de tip outlier (valori extreme).

Recomandarea de business derivată de aici este dezvoltarea unor oferte VIP personalizate pentru clienții care se situează în ultimul decil de balanță, separându-i de campaniile de masă (mass-market).

Problema 5

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic central al acestei etape este profilarea avansată a clienților prin segmentare multi-criterială. Managementul băncii are nevoie să înțeleagă în profunzime trei aspecte de business fundamentale pentru optimizarea viitoarelor campanii. Primul aspect vizează distribuția bunăstării financiare în funcție de profesie, pentru a putea calibra pragurile minime de constituire a depozitelor. Al doilea aspect urmărește evaluarea gradului de supra-îndatorare a portofoliului printr-o analiză de risc încrucișată între creditele ipotecare și cele de nevoi personale. Nu în ultimul rând, se dorește înțelegerea relației dintre stabilitatea familială, dictată de starea civilă, și propensiunea spre economisire, reprezentată de decizia finală de subscriere la campania de atragere de fonduri.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru a genera aceste tablouri de bord analitice, au fost extrase și prelucrate mai multe variabile esențiale din setul de date. Variabilele care descriu ocupația și soldul contului au fost analizate împreună pentru determinarea lichidității medii aferente fiecărui profil profesional. În paralel, pentru analiza de risc și a gradului de îndatorare multiplă, s-au utilizat variabilele categoriale binare care indică prezența unui credit ipotecar activ și a unui credit de consum. De asemenea, starea civilă a clientului a fost pusă în relație directă cu variabila țintă a campaniei, și anume decizia de a deschide un depozit la termen, cu scopul de a măsura cu precizie rata de conversie pe segmente demografice distincte.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Din punct de vedere metodologic, prelucrările se bazează pe paradigma grupării și agregării de tip divizează, aplică și combină, folosind instrumentele specifice pachetului Pandas. Pentru agregarea seriilor numerice s-a aplicat funcția de calcul a mediei aritmetice, generând astfel un profil statistic clar al veniturilor. O tehnică analitică avansată utilizată în această secțiune este crearea tabelelor de contingență, care a permis calcularea frecvențelor absolute bivariate. Această metodă numără aparițiile încrucișate și pivotează datele dintr-un format tabelar clasic într-o structură matriceală orizontală. Pentru a asigura rigoarea matematică a rezultatelor, s-a recurs la imputarea datelor nule, garantând astfel că intersecțiile de categorii fără înregistrări preexistente sunt tratate statistic ca având o frecvență absolută zero, prevenind orice eroare computațională.

d) Prezentarea rezultatelor: capturi de ecran

Balanța medie pe tip de ocupație

job	balance
0 admin.	1297.2416
1 blue-collar	1333.7061
2 entrepreneur	1689.9394
3 housemaid	1319.6732
4 management	1798.8557
5 retired	2417.2506
6 self-employed	1971.2872
7 services	1235.9324
8 student	1279.7333
9 technician	1614.331

Cati dintre cei care au credit ipotecar au si credit de nevoi personale ↻

	housing	Nu au credit de nevoi personale (No)	Au credit de nevoi personale (Yes)
0	no	4062	483
1	yes	3457	657

Subscrieri la depozit în funcție de starea civilă

	marital	Au refuzat (No)	Au acceptat (Yes)
0	divorced	634	589
1	married	3204	2493
2	single	883	856

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Interpretarea economică a acestor tabele de contingență oferă direcții strategice de acțiune extrem de valoroase pentru organizație. Analiza pe profesii evidențiază categoriile care dețin cel mai mare capital blocat în conturi curente, cum ar fi pozițiile de management sau clienții aflați la pensie, sugerând necesitatea ca ofițerii de cont să prioritizeze aceste grupuri cu potențial ridicat. Mai departe, analiza de risc încrucișat scoate la iveală clienții afectați de o îndatorare dublă. Pentru acest segment supra-îndatorat, o ofertă de depozit la termen ar fi inefficientă din cauza lipsei de lichidități, fiind mult mai oportună direcționarea lor către campanii de refinanțare. În final, corelarea deciziei de subscriere cu starea civilă permite departamentului de marketing să descopere diferențe comportamentale notabile. Identificarea unor segmente mai receptive, cum ar fi persoanele necăsătorite, fundamentează recomandarea de a lansa campanii de economisire nișate, care să maximizeze rata de succes și să reducă timpul alocat apelurilor telefonice neproductive.

Problema 6

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic central al acestei secțiuni este transpunerea datelor tabelare brute în vizualizări grafice interactive pentru a facilita o înțelegere rapidă și intuitivă a dinamicii portofoliului de clienți. Managementul băncii necesită un tablou de bord care să sintetizeze informația complexă în formate vizuale ușor de interpretat, permițând identificarea imediată a tendințelor comportamentale, a sezonality și a distribuției riscului. Prin utilizarea acestor reprezentări vizuale, decidenții pot evalua instantaneu performanța globală a campaniei, structura riscului de creditare pe segmente educaționale, momentele optime pentru contactarea clienților și relația dintre lichidități și gradul de îndatorare pe termen scurt, optimizând astfel alocarea resurselor bugetare și de marketing.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru generarea acestor reprezentări grafice complexe s-au utilizat variabile care acoperă atât dimensiunea financiară, cât și pe cea demografică și operațională a bazei de date. Variabila țintă, reprezentată de decizia de a constitui un depozit, a fost utilizată direct pentru a calcula rata generală de conversie și pentru a analiza receptivitatea clienților în funcție de luna de contact. Variabilele reprezentând nivelul de educație și deținerea unui credit ipotecar au fost încrucișate pentru a vizualiza profilul de risc imobiliar distribuit pe

segmente de studii. În plus, variabilele care indică deținerea unui credit de nevoi personale și balanța contului curent au fost folosite împreună pentru a ilustra distribuția statistică a lichidităților în funcție de tipul de îndatorare activă a clientului analizat.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Din perspectivă tehnică și algoritmică, această etapă se bazează pe biblioteca de vizualizare interactivă Plotly, care permite randarea dinamică a graficelor direct în interfața aplicației web. S-au utilizat metode prealabile de grupare și agregare a datelor pentru a calcula volumele absolute necesare diagramelor cu bare și de dispersie. Concret, s-au aplicat algoritmi de randare pentru diagrame circulare de tip inel destinate ilustrării proporțiilor macro, diagrame cu bare grupate pentru compararea frecvențelor bivariante, diagrame de dispersie pentru urmărirea evoluției cronologice și diagrame de tip box-plot pentru reprezentarea statistică robustă a distribuției. Pentru diagrama box-plot, algoritmul a extras mediana, quartilele superioare și inferioare, limitând programatic axa ordonatelor pentru a exclude vizual extremele statistice care ar fi distorsionat scara graficului și interpretarea acestuia.

d) Prezentarea rezultatelor: capturi de ecran

Vizualizarea Interactivă a Datelor



e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Interpretarea economică a acestui tablou grafic oferă conducerii perspective acționabile pe multiple paliere de business. Graficul ratei de conversie arată clar eficiența brută a campaniei actuale, un procent de succes scăzut semnalând necesitatea urgentă de a abandona telemarketingul generalizat în favoarea unui bazat pe modele predictive. Diagrama corelării dintre educație și creditele ipotecare ajută departamentul de risc să înțeleagă unde este concentrată masa creditării pe termen lung, putând adapta ofertele de refinanțare pentru clienții cu studii superioare, care de regulă atrag volume mai mari de finanțare. Graficul de sezonabilitate demonstrează exact în ce luni clienții sunt cel mai receptivi la economisire, fundamentând direct recomandarea de a suplimenta personalul din call-center în perioadele de vârf identificate vizual. Nu în ultimul rând, diagrama box-plot dezvăluie faptul că persoanele fără credite de nevoi personale au o mediană a lichidităților mai ridicată și o volatilitate diferită a contului, confirmând ipoteza analitică conform căreia acestea reprezintă publicul țintă ideal pentru viitoarele campanii de atragere a depozitelor la termen.

Problema 7

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic central al acestei secțiuni este tranziția de la o analiză retrospectivă la una proactivă, bazată pe inteligența artificială și modelarea predictivă, cu scopul de a maximiza randamentul investițiilor (ROI) în marketingul direct. Managementul băncii dorește rezolvarea a trei probleme majore: segmentarea automată a bazei de date pentru a descoperi profiluri ascunse de clienți, anticiparea probabilității ca un client să accepte oferta financiară pentru a elimina apelurile inutile (cold-calling) și evaluarea factorilor care influențează consumul resursei de timp (durata apelurilor) în call-center. Prin soluționarea acestor probleme, organizația trece de la o abordare bazată pe volum la una bazată pe precizie, vizând reducerea costurilor operaționale și creșterea ratei de conversie.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru antrenarea modelelor matematice s-a selectat un subset relevant de variabile, evitându-se supraîncărcarea sau distorsionarea algoritmilor (cursa dimensionalității). Pentru segmentarea clienților (clusterizare) s-au utilizat exclusiv variabilele numerice continue „age” (vârstă) și „balance” (sold bancar). Pentru modelul de clasificare binară, variabila dependentă (țintă) a fost decizia de subscriere („deposit”), transformată algoritmic, în timp ce variabilele independente au inclus istoricul de creditare („default”, „housing”, „loan”), eficiența campaniilor („campaign”, „outcome”) și detaliile de contact („duration”). În mod complementar, pentru evaluarea efortului operațional, variabila „duration” a devenit variabilă dependentă în modelul de regresie multiplă, fiind explicată prin intermediul tuturor celorlalte attribute demografice și financiare extrase.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Din perspectivă metodologică, secțiunea integrează tehnici de preprocesare a datelor și trei paradigme distincte de Machine Learning. În faza de pregătire, s-a utilizat algoritmul de codificare „One-Hot Encoding” pentru a binariza variabilele text (transformându-le în coordonate de 0 și 1) și Standardizarea (StandardScaler) pentru a aduce variabilele numerice la o scară comună (Z-score). Pentru identificarea profilurilor de clienți, s-a aplicat algoritmul de învățare nesupervizată K-Means, care minimizează varianța

intra-cluster pe baza distanței euclidiene. Pentru predicția deciziei clientului s-a utilizat Regresia Logistică, un model de învățare supervizată care aplică funcția sigmoidă pentru a estima probabilitățile de apartenență la clasa de succes. În final, inferența statistică privind durata apelurilor a fost realizată printr-un model de Regresie Liniară Multiplă, estimat prin metoda celor mai mici pătrate ordinare (OLS), utilizând pachetul Statsmodels pentru a extrage coeficienții de impact și nivelul de semnificație (p-value).

d) Prezentarea rezultatelor: capturi de ecran


Modele Predictive și Machine Learning

1. Pregătirea Datelor

Datele după codificare (primele 5 rânduri):

	age	balance	duration	campaign	default_yes	housing_yes	loan_yes	poutcome_other	poutcome_success	poutcome_unknown	deposit_yes
0	59	2343	1042	1	☐	☒	☐	☐	☐	☒	☒
1	56	45	1467	1	☐	☐	☐	☐	☐	☒	☒
2	41	1270	1389	1	☐	☒	☐	☐	☐	☒	☒
3	55	2476	579	1	☐	☒	☐	☐	☐	☒	☒
4	54	184	673	2	☐	☐	☐	☐	☐	☒	☒

2. Segmentarea Clienților (Clusterizare K-Means)



3. Predicția Subscrierii (Regresie Logistică)

Acuratețea Modelului Logistic

78.01%

Raport de Clasificare Detaliat:

	precision	recall	f1-score	support
False	0.769	0.828	0.797	1166.000
True	0.794	0.728	0.760	1067.000
accuracy	0.780	0.780	0.780	0.780
macro	0.782	0.778	0.779	2233.000
weighted	0.781	0.780	0.779	2233.000

Cum se citesc aceste metrice?

- Precision (Precizia):** Dintre toți clienții pe care modelul i-a prezis ca fiind 'Da', câți au zis 'Da' în realitate? (Ajută la reducerea apelurilor inutile).
- Recall (Senzitivitatea):** Dintre toți clienții care au zis 'Da' în realitate, pe câți a reușit modelul să îi găsească?
- F1-Score:** Media armonică dintre Precizie și Recall.

Vezi detalii tehnice (Matricea de Confuzie)

0	1
965	201
290	777

3. Regresie Multiplă OLS: Ce influențează durata apelului?

Analizăm ce factori (vârstă, balanță, decizie etc.) prelungesc sau scurtează timpul petrecut la telefon cu un client.

Tabelul Coeficienților:

	coef	std err	t	P> t	[0.025	0.975]
const	77.7793	14.745	5.275	0.000	48.877	106.681
age	0.3827	0.244	1.572	0.116	-0.095	0.860
balance	-4.373e-05	0.001	-0.049	0.961	-0.002	0.002
campaign	0.2280	1.060	0.215	0.830	-1.849	2.305
default_yes	-4.6411	23.479	-0.198	0.843	-50.665	41.382
housing_yes	88.9665	5.947	14.959	0.000	77.309	100.624
loan_yes	34.6040	8.547	4.049	0.000	17.850	51.358
poutcome_other	5.1504	15.559	0.331	0.741	-25.349	35.649
poutcome_success	-110.8385	12.890	-8.599	0.000	-136.105	-85.572
poutcome_unknown	88.3783	9.270	9.534	0.000	70.208	106.549
deposit_yes	371.1053	6.124	60.602	0.000	359.102	383.109

Capacitatea explicativă a modelului (R-squared): 0.2526

Interpretare Economică (Exemplu):

Dacă te uiți la coeficientul (coef) variabilei `deposit_yes`, vei observa un număr pozitiv mare. Asta înseamnă că apelurile care se finalizează cu un succes ('Da') durează în medie cu acel număr de secunde mai mult decât cele care se finalizează cu un refuz.

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Interferențele economice rezultate din aplicarea acestor modele sunt fundamentale pentru optimizarea strategiei băncii. Clusterizarea K-Means demonstrează vizual existența unor segmente de piață clar delimitate (de exemplu, clienți maturi cu acumulări majore de capital versus tineri cu balanțe reduse), permițând departamentului de marketing să personalizeze pachetele promoționale pentru fiecare micro-segment. Analiza metricilor din Regresia Logistică, în special indicatorii de Precizie (Precision) și Senzitivitate (Recall), confirmă viabilitatea utilizării inteligenței artificiale pentru pre-filtrarea listelor de apeluri. Recomandarea este ca agenții să contacteze exclusiv clienții pe care modelul îi marchează cu o probabilitate ridicată de succes, eliminând astfel pierderile de timp generate de refuzurile sigure. Prin intermediul modelului OLS, banca poate cuantifica direct relația dintre profilul clientului și timpul petrecut la telefon. Dacă rezultatele indică, de exemplu, că decizia de a subscrie crește semnificativ durata apelului, managementul de resurse umane (HR) trebuie să revizuiască targeturile zilnice de apeluri ale agenților, acceptând un volum mai mic de contactări în favoarea unor conversații mai lungi, dar calitative și profitabile.

SAS

Problema 1

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic central al acestei prime etape din mediul SAS este standardizarea și pregătirea bazei de date brute pentru analizele statistice ulterioare, un pas fundamental în orice proces de guvernanță a datelor. În practica de business, datele extrase direct din sistemele tranzacționale prezintă adesea neconcordanțe de formatare și necesită o prelucrare riguroasă înainte de a fi utilizate în raportarea către management. Organizația are nevoie de o bază de date curată, în care informațiile tehnice să fie traduse în categorii economice intuitive. Astfel, prin crearea unor noi indicatori de risc, cum ar fi numărul total de credite active, și prin segmentarea soldurilor bancare în clase de lichiditate, se construiește o fundație solidă care va permite departamentului de risc și celui de marketing să evalueze rapid bonitatea și potențialul investițional al fiecărui client din portofoliu.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru realizarea acestei proceduri de import și transformare, s-au utilizat variabile structurale esențiale extrase din fișierul de tip text. Au fost importate variabile demografice și financiare brute precum ocupația, vârsta, soldul contului, alături de indicatori binari de creditare, cum ar fi existența creditelor ipotecare și a celor de consum. Pe parcursul etapei de procesare, aceste atribute au stat la baza creării unor noi metrice derivate. Mai exact, pe baza soldului brut s-a construit o nouă variabilă categorială care indică profilul de economisire al clientului, iar prin consolidarea variabilelor de creditare a rezultat o nouă variabilă numerică menită să cuantifice gradul agregat de îndatorare activă a fiecărui individ, informație vitală pentru evaluarea bonității.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Metodele utilizate în această secțiune sunt specifice arhitecturii limbajului SAS și se bazează pe blocuri de prelucrare a observațiilor. Importul datelor externe s-a realizat prin

instrucțiunea de citire secvențială din fișier, definindu-se explicit lungimea alfanumerică a fiecărui câmp pentru a preveni trunchierea informației. Pentru standardizarea vizuală s-au definit formate personalizate prin procedura dedicată, iar la nivel de rând s-au aplicat funcții integrate pentru corectarea gramaticală a textelor și pentru plafonarea matematică a valorilor negative aferente zilelor de contact. Din punct de vedere algoritmic, o tehnică avansată utilizată este procesarea iterativă prin intermediul structurilor de tip masiv unidimensional. Acest algoritm a parcurs buclat variabilele de creditare pentru a calcula scorul total de îndatorare, optimizând astfel timpii de execuție. De asemenea, a fost implementată procesarea condițională multiplă de tip ramificat pentru a încadra matematic fiecare client într-o anumită categorie de risc pe baza unor praguri de lichiditate prestabilite.

d) Prezentarea rezultatelor: capturi de ecran

```

1      OPTIONS NONOTES NOSTIMER NOSOURCE NOSYNTAXCHECK;
68
69      proc format;
70          value $decizie_fmt
71              'yes' = 'Acceptat'
72              'no'  = 'Refuzat';
NOTE: Format $DECIZIE_FMT has been output.
73          value varsta_grp
74              18 - 30 = 'Tânăr'
75              31 - 50 = 'Adult'
76              51 - high = 'Senior';
NOTE: Format VARSTA_GRP has been output.
77      run;

```

CODE

LOG

RESULTS

OUTPUT DATA

Table:

WORK.BANCA_RAW

 | View:

Column names

 | | Filter: (none)

Total rows: 11162 Total columns: 18

↩

⬅

 Rows 1-100

➡

⏹

	job	marital	education	default	housing	loan	contact	month	poutcome	y	
1	admin.	married	secondary	no	yes	no	unknown	may	unknown	yes	
2	admin.	married	secondary	no	no	no	unknown	may	unknown	yes	
3	technician	married	secondary	no	yes	no	unknown	may	unknown	yes	
4	services	married	secondary	no	yes	no	unknown	may	unknown	yes	
5	admin.	married	tertiary	no	no	no	unknown	may	unknown	yes	
6	management	single	tertiary	no	yes	yes	unknown	may	unknown	yes	
7	management	married	tertiary	no	yes	yes	unknown	may	unknown	yes	
8	retired	divorced	secondary	no	yes	no	unknown	may	unknown	yes	
9	technician	married	secondary	no	yes	no	unknown	may	unknown	yes	
10	services	single	secondary	no	yes	no	unknown	may	unknown	yes	
11	admin.	single	secondary	no	yes	no	unknown	may	unknown	yes	
12	blue-collar	married	secondary	no	yes	no	unknown	may	unknown	yes	
13	management	married	tertiary	no	yes	yes	unknown	may	unknown	yes	
14	blue-collar	single	tertiary	no	yes	no	unknown	may	unknown	yes	
15	technician	single	tertiary	no	yes	no	unknown	may	unknown	yes	
16	management	divorced	tertiary	no	yes	no	unknown	may	unknown	yes	
17	blue-collar	single	primary	no	yes	no	unknown	may	unknown	yes	

CODE

LOG

RESULTS

OUTPUT DATA

Table:

WORK.BANCA_RAW

View:

Column names

Filter: (none)

Total rows: 11162

Total columns: 18

Rows 1-100

balance	day	duration	campaign	pdays	previous
2343	5	1042	1	-1	0
45	5	1467	1	-1	0
1270	5	1389	1	-1	0
2476	5	579	1	-1	0
184	5	673	2	-1	0
0	5	562	2	-1	0
830	6	1201	1	-1	0
545	6	1030	1	-1	0
1	6	608	1	-1	0
5090	6	1297	3	-1	0
100	7	786	1	-1	0
309	7	1574	2	-1	0
199	7	1689	4	-1	0
460	7	1102	2	-1	0
703	8	943	2	-1	0
3837	8	1084	1	-1	0
611	8	541	3	-1	0

Total rows: 11162

Total columns: 22

Rows 1-100

previous	id_client	job_curat	zile_de_la_ultimul_contact	numar_credite_active	categorie_bani
0	1	Admin.	0	1	Premium
0	2	Admin.	0	0	Economii
0	3	Technician	0	1	Premium
0	4	Services	0	1	Premium
0	5	Admin.	0	0	Economii
0	6	Management	0	2	Fără f
0	7	Management	0	2	Economii
0	8	Retired	0	1	Economii
0	9	Technician	0	1	Economii
0	10	Services	0	1	Premium
0	11	Admin.	0	1	Economii
0	12	Blue-Collar	0	1	Economii
0	13	Management	0	2	Economii
0	14	Blue-Collar	0	1	Economii
0	15	Technician	0	1	Economii
0	16	Management	0	1	Premium
0	17	Blue-Collar	0	1	Economii

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Dincolo de simpla igienizare a bazei de date, transformările efectuate în această etapă generează o valoare economică imediată prin facilitarea deciziilor strategice. Variabila care consolidează numărul de credite active oferă ofițerilor de risc un semnal de alarmă instantaneu cu privire la clienții potențial supra-îndatorați, care ar putea prezenta un risc de neplată în viitor sau care nu dispun de fonduri pentru produse noi. Totodată, segmentarea automată a clienților în categorii clare de lichiditate simplifică enorm munca departamentului de vânzări. Recomandarea de business derivată din acest pas este ca analiștii de marketing să utilizeze direct aceste noi etichete personalizate pentru a exclude din start clienții marcați

drept datornici și pentru a direcționa resursele call-center-ului cu prioritate către clienții etichetați drept premium, maximizând astfel eficiența alocării bugetului de promovare.

Problema 2

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic principal al acestei etape este unificarea surselor de date fragmentate și generarea unor instrumente de decizie sintetice, esențiale pentru managementul executiv. În mediul corporativ real, departamentele organizației, cum ar fi cel de resurse umane, marketing sau analiză financiară, operează adesea cu baze de date izolate (data silos). Soluționarea acestei probleme presupune fuzionarea informațiilor disparate pentru a obține o perspectivă integrată, de ansamblu, asupra fiecărui client. Ulterior consolidării, obiectivul derivat este extragerea de inteligență de business prin construirea unor rapoarte agregate și a unor vizualizări grafice care să descrie profilul financiar și demografic al clienților, facilitând astfel decizii strategice rapide privind targetarea campaniilor și alocarea bugetelor operaționale.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru a simula izolarea departamentală și ulterior consolidarea portofoliului, au fost divizate și reasamblate atât atribute demografice, cât și indicatori financiari de performanță. Setul demografic a reținut variabile precum cheia unică de identificare a clientului, vârsta, starea civilă, nivelul de educație și profesia standardizată anterior. În paralel, setul financiar a păstrat indicatorii monetari și comportamentali, incluzând balanța contului curent, indicatorul calculat al creditelor active, durata interacțiunii telefonice și variabila țintă reprezentând decizia de subscriere la depozit. Această variabilă țintă, împreună cu variabila continuă ce descrie vârsta, a constituit fundamentul generării reprezentărilor grafice, în timp ce ocupația clientului și atributele financiare au alimentat raportul agregat de business.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Din perspectivă tehnologică, s-au aplicat proceduri fundamentale și de nivel avansat specifice ecosistemului SAS. Pentru compartimentarea informației s-au utilizat clauze de filtrare de tipul WHERE și instrucțiuni condiționale IF pentru selecția strictă a observațiilor, completate de comanda KEEP pentru proiecția coloanelor necesare. Ulterior, pentru consolidarea datelor s-a apelat la limbajul de interogare structurat, implementând procedura SQL pentru a efectua o joncțiune internă (Inner Join) fundamentată pe cheia primară a clienților. Pentru sumarizarea informațiilor a fost utilizată o procedură avansată de raportare, calculând media aritmetică a indicatorilor financiari la nivel de grup profesional, cu aplicarea unor formate numerice specifice. În etapa finală, a fost generată o diagramă casetată de tip box-plot prin intermediul procedurilor statistice de vizualizare, aplicându-se formate predefinite definite de utilizator pentru traducerea valorilor tehnice brute în etichete lizibile și cu sens economic.

d) Prezentarea rezultatelor: capturi de ecran

CODE LOG RESULTS OUTPUT DATA

Table: WORK.BANCA_DEMOGRAFIC View: Column names Filter: (none)

Total rows: 10551 Total columns: 5

	marital	education	age	id_client	job_curat
1	married	secondary	59	1	Admin.
2	married	secondary	56	2	Admin.
3	married	secondary	41	3	Technician
4	married	secondary	55	4	Services
5	married	tertiary	54	5	Admin.
6	single	tertiary	42	6	Management
7	married	tertiary	56	7	Management
8	divorced	secondary	60	8	Retired
9	married	secondary	37	9	Technician
10	single	secondary	28	10	Services
11	single	secondary	38	11	Admin.
12	married	secondary	30	12	Blue-Collar
13	married	tertiary	29	13	Management
14	single	tertiary	46	14	Blue-Collar
15	single	tertiary	31	15	Technician
16	divorced	tertiary	35	16	Management
17	single	primary	32	17	Blue-Collar
18	married	secondary	49	18	Services

Messages: 5 User: u64501191

Table: WORK.BANCA_FINANCIAR View: Column names Filter: (none)

Total rows: 11162 Total columns: 5

	y	balance	duration	id_client	numar_credite_active
1	yes	2343	1042	1	1
2	yes	45	1467	2	0
3	yes	1270	1389	3	1
4	yes	2476	579	4	1
5	yes	184	673	5	0
6	yes	0	562	6	2
7	yes	830	1201	7	2
8	yes	545	1030	8	1
9	yes	1	608	9	1
10	yes	5090	1297	10	1
11	yes	100	786	11	1
12	yes	309	1574	12	1
13	yes	199	1689	13	2
14	yes	460	1102	14	1
15	yes	703	943	15	1
16	yes	3837	1084	16	1
17	yes	611	541	17	1
18	yes	-8	1119	18	1

Messages: 5 User: u64501191


Table: WORK.BANCA_FINAL | View: Column names | Filter: (none)

Total rows: 10551 | Total columns: 8

	id_client	age	job_curat	marital	balance	numar_credite_activ
1	1	59	Admin.	married	2343	
2	2	56	Admin.	married	45	
3	3	41	Technician	married	1270	
4	4	55	Services	married	2476	
5	5	54	Admin.	married	184	
6	6	42	Management	single	0	
7	7	56	Management	married	830	
8	8	60	Retired	divorced	545	
9	9	37	Technician	married	1	
10	10	28	Services	single	5090	
11	11	38	Admin.	single	100	
12	12	30	Blue-Collar	married	309	
13	13	29	Management	married	199	
14	14	46	Blue-Collar	single	460	
15	15	31	Technician	single	703	
16	16	35	Management	divorced	3837	
17	17	32	Blue-Collar	single	611	

Raport de Business: Profilul financiar pe meserii

Ocupație (Job)	Medie Credite Active	Balanța Medie (Euro)
Admin.	0.74	1184.5
Blue-Collar	0.86	1207.7
Entrepreneur	0.74	1595.6
Housemaid	0.39	1368.7
Management	0.53	1790.1
Retired	0.45	1749.8
Self-Employed	0.58	1571.5
Services	0.78	1056.8
Student	0.14	1500.8
Technician	0.62	1552.8
Unemployed	0.38	1313.0
Unknown	0.08	1857.7



e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Concluziile derivate din analiza acestor rapoarte și grafice sunt direct aplicabile în formularea strategiei comerciale a organizației. Raportul agregat pe categorii profesionale permite conducerii executive să identifice instantaneu profesiile caracterizate printr-un surplus constant de lichidități și un grad redus de îndatorare, acestea constituind publicul țintă primordial pentru produsele de economisire premium. De asemenea, graficul casetat privind distribuția vârstei oferă un fundament analitic critic referitor la profilul demografic al respondenților pozitivi. Observând vizual asimetriile de distribuție sau diferențele de nivel ale mediei între clienții care au acceptat și cei care au refuzat oferta, se pot deduce tendințe clare de economisire dictate de ciclul de viață. Dacă analiza indică o propensiune spre economisire semnificativ mai ridicată la anumite categorii de vârstă, se recomandă departamentului de marketing să își reorienteze eforturile publicitare exclusiv către acele segmente, maximizând astfel eficiența ratei de conversie și rata rentabilității investițiilor.

Problema 3

a) Definirea problemei: obiectivul economic vizat

Obiectivul economic central al acestei etape avansate este tranziția de la analiza retrospectivă a portofoliului la modelarea predictivă, cu scopul direct de a optimiza campaniile de marketing direct ale băncii. Problema fundamentală a telemarketingului este costul ridicat de oportunitate generat de contactarea unor clienți cu potențialul de conversie. Prin antrenarea acestui model statistic, banca urmărește să calculeze o probabilitate individualizată de succes pentru fiecare client în parte. Astfel, organizația poate abandona contactarea masivă și nediferențiată în favoarea unei strategii chirurgicale,

direcționând forța de vânzări din call-center exclusiv către segmentele cu cea mai mare propensiune de a deschide un depozit la termen, maximizând rata de răspuns și reducând simultan costurile operaționale.

b) Informații necesare pentru rezolvare: descrierea variabilelor utilizate

Pentru a antrena acest model predictiv, s-au selectat cu atenție variabile economice și demografice cu un potențial explicativ ridicat. Variabila dependentă, sau ținta modelului, este decizia binară a clientului de a subscrie la depozit. Această decizie este explicată prin intermediul unui mix de variabile independente, atât calitative, cât și cantitative. Din categoria variabilelor continue s-au inclus vârsta cronologică, soldul disponibil al contului, numărul total de credite active și durata în secunde a interacțiunii telefonice. Concomitent, s-au integrat și variabile categoricale esențiale, precum ocupația profesională și starea civilă, pentru a capta influența factorilor socio-demografici și a stabilității familiale asupra comportamentului financiar de economisire.

c) Metode de calcul, algoritmi, formule de calcul utilizate

Din punct de vedere metodologic, s-a utilizat procedura de regresie logistică specifică pachetului statistic SAS, o metodă consacrată pentru modelarea variabilelor dependente dihotomice. Algoritmul aplică metoda estimării de maximă verosimilitate (Maximum Likelihood Estimation) pentru a aproxima coeficienții care maximizează probabilitatea observării datelor din eșantion. Un aspect tehnic crucial al implementării este utilizarea opțiunii de ordonare descrescătoare a variabilei țintă, care forțează algoritmul să modeleze direct probabilitatea evenimentului pozitiv, respectiv acceptarea ofertei. De asemenea, variabilele categoricale au fost declarate explicit în clauza de clasificare, utilizând parametrizarea prin referință. Astfel, algoritmul generează automat variabile de tip indicator (dummy variables), permițând cuantificarea matematică a impactului fiecărei profesii sau stări civile în raport cu o categorie de bază.

d) Prezentarea rezultatelor: capturi de ecran

Modelul Logistic Predictiv pentru Depozite

The LOGISTIC Procedure

Model Information	
Data Set	WORK.BANCA_FINAL
Response Variable	y
Number of Response Levels	2
Model	binary logit
Optimization Technique	Fisher's scoring

Number of Observations Read	10551
Number of Observations Used	10551

Response Profile		
Ordered Value	y	Total Frequency
1	Refuzat	5764
2	Acceptat	4787

Probability modeled is y="Refuzat".

Model Convergence Status	
Convergence criterion (GCONV=1E-8) satisfied.	

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	14538.194	10742.736
SC	14545.458	10779.056
-2 Log L	14536.194	10732.736

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	3803.4579	4	<.0001
Score	2929.1749	4	<.0001
Wald	2121.6138	4	<.0001

Analysis of Maximum Likelihood Estimates					
Parameter	DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept	1	0.3463	0.1038	11.1178	0.0009
age	1	0.0244	0.00242	102.0291	<.0001
balance	1	-0.00005	8.395E-6	33.7026	<.0001
numar_credite_active	1	1.0090	0.0415	591.2189	<.0001
duration	1	-0.00484	0.000113	1838.4817	<.0001

Odds Ratio Estimates			
Effect	Point Estimate	95% Wald Confidence Limits	
age	1.025	1.020	1.030
balance	1.000	1.000	1.000
numar_credite_active	2.743	2.529	2.975
duration	0.995	0.995	0.995

Association of Predicted Probabilities and Observed Responses			
Percent Concordant	84.0	Somers' D	0.680
Percent Discordant	16.0	Gamma	0.680
Percent Tied	0.0	Tau-a	0.337
Pairs	27592268	c	0.840

e) Interpretarea economică a rezultatelor: concluzii și recomandări pentru business

Interpretarea economică a estimărilor logistice oferă managementului cel mai înalt grad de inteligență decizională. Analizând tabelul coeficienților și nivelul lor de semnificație, decidenții pot observa direcția clară a influenței fiecărui factor. De exemplu, un coeficient negativ și semnificativ statistic pentru indicatorul creditelor active confirmă riguros ipoteza că gradul de îndatorare anulează capacitatea de economisire, justificând excluderea completă a acestui profil din listele de apeluri. Pe de altă parte, analiza rapoartelor de șanse pentru variabilele demografice permite ierarhizarea exactă a meseriilor. Dacă modelul indică faptul că o categorie precum clienții pensionari are o probabilitate semnificativ mai mare să accepte oferta comparativ cu categoria de referință, recomandarea strategică directă este concentrarea bugetului de marketing pe acest segment demografic, garantând o rentabilitate superioară a resurselor băncii.